

Wiederholung: Gradient

- ▶ Gradientenvektor
- ▶ Betrag & Richtung

Beschreibung von Struktur

- ▶ Strukturtensor
- ▶ Orientierung & Kohärenz
- ▶ Eckpunkte

Finden lokaler Konturformen

Kanten

Ziel von Ableitungsfiltern ist das Finden von

- ▶ Kanten, Ecken und lokalen Extremwerten

im Ortsraum. Das geschieht hauptsächlich über eine Auswertung des

- ▶ Gradientenvektors.


Kanten werden durch die

- ▶ die Richtung

und die

- ▶ den Betrag

des Gradientenvektors beschrieben.



Finden lokaler Konturformen


Gradientenvektor

Die partiellen Ableitungen der Bildfunktion entlang beider Dimensionen an einem Bildort $\mathbf{x}$ ergeben den **Gradientenvektor** ∇

$$\nabla(\mathbf{x}) = \left[\frac{\partial G(\mathbf{x})}{\partial x}, \frac{\partial G(\mathbf{x})}{\partial y} \right]^T,$$


mit dem **Betrag des Gradientenvektors**

$$\|\nabla\| = \sqrt{\nabla^T \nabla} = \sqrt{\left(\frac{\partial G(\mathbf{x})}{\partial x} \right)^2 + \left(\frac{\partial G(\mathbf{x})}{\partial y} \right)^2}.$$



Finden lokaler Konturformen

Beispiel Betrag des Gradienten



Finden lokaler Konturformen

Gradientenvektor


Die **Richtungsableitung** entlang der Richtung θ

$$\nabla^\top \mathbf{n} = \cos(\theta) \frac{\partial G(\mathbf{x})}{\partial x} + \sin(\theta) \frac{\partial G(\mathbf{x})}{\partial y}$$

gibt die Stärke der Änderung entlang dieser Richtung an und entspricht dem Skalarprodukt zwischen Richtungsvektor $\mathbf{n}$ und Gradient ∇

$$\langle \nabla, \mathbf{n} \rangle = \|\nabla\| \cos(\theta - \theta'),$$

wobei $\mathbf{n} = [\cos(\theta), \sin(\theta)]^\top$, mit $\|\mathbf{n}\| = 1$.



Finden lokaler Konturformen

Gradientenvektor

Im einfachsten Fall kann der Winkel θ_0 des steilsten Abstiegs über die Maximierung der Richtungsableitung nach der Richtung berechnet werden:



$$\frac{\partial}{\partial \theta} \left(\cos(\theta) \frac{\partial G(\mathbf{x})}{\partial x} + \sin(\theta) \frac{\partial G(\mathbf{x})}{\partial y} \right) \stackrel{!}{=} 0.$$

$$\tan(\theta_0) = \frac{\partial G(\mathbf{x})}{\partial y} \left(\frac{\partial G(\mathbf{x})}{\partial x} \right)^{-1} \quad \leftrightarrow \quad \theta_0 = \tan^{-1} \left(\frac{\partial G(\mathbf{x})}{\partial y} \left(\frac{\partial G(\mathbf{x})}{\partial x} \right)^{-1} \right).$$

Dies entspricht der **Richtung des Gradientenvektors**.

Finden lokaler Konturformen

Beispiel Richtung des Gradienten





Strukturtensor - Motivation

Ein wesentliches Merkmal zum Beschreiben von kleinen Bildregionen ist die sogenannte **Struktur**. Sie wird durch Größen, wie

- ▶ die **Orientierung** und
- ▶ die **Kohärenz**

charakterisiert. Im Unterschied zur Richtung, die im Bereich von Null bis 360° definiert ist, beschreibt die Orientierung eine Vorzugsrichtung ohne zwischen positiven und negativen Ableitungen zu unterscheiden. Man möchte wissen, ob eine lokale Struktur eine gewisse Vorzugsrichtung bei den einzelnen Gradienten aufweist und wie stark diese Vorzugsrichtung ausgeprägt ist.



Strukturtensor - Definition

Der Strukturtensor $\mathbf{J}(\mathbf{x})$ ist für eine bestimmte Nachbarschaft $\mathcal{N}(\mathbf{x})$ mit einer bestimmten Gewichtung $W(\mathbf{x} - \mathbf{x}')$ um den Punkt $\mathbf{x}$ folgendermaßen definiert:

$$\mathbf{J}(\mathbf{x}) = \begin{bmatrix} J_{11}(\mathbf{x}) & J_{12}(\mathbf{x}) \\ J_{12}(\mathbf{x}) & J_{22}(\mathbf{x}) \end{bmatrix} = \int_{\mathbf{x}' \in \mathcal{N}(\mathbf{x})} W(\mathbf{x} - \mathbf{x}') (\nabla(\mathbf{x}') \nabla(\mathbf{x}')^\top) d\mathbf{x}' = \mathbf{W} * (\nabla \nabla^\top).$$

Das entspricht im 2D einer symmetrischen 2×2 -Matrix, wobei die einzelnen Elemente gewichtete Mittelungen der Ableitungskombinationen $(\partial G(\mathbf{x})/\partial x)^2$, $(\partial G(\mathbf{x})/\partial y)^2$ und $(\partial G(\mathbf{x})/\partial x)(\partial G(\mathbf{x})/\partial y)$ entsprechen.

Das Quadrat der Projektion $(\nabla(\mathbf{x})^\top \mathbf{n})^2$ zwischen Gradientenvektor und einer Vorzugsrichtung $\mathbf{n} = [\cos(\theta), \sin(\theta)]^\top$ beschreibt die Abweichung zu einer bestimmten Orientierung. Die Orientierung, welche die geringste mittlere Abweichung zu allen Gradientenvektoren in der Nachbarschaft $\mathcal{N}(\mathbf{x})$ erzeugt, wird als Orientierung der lokalen Struktur definiert.

Strukturtensor - Orientierung

Die Orientierung der lokalen Umgebung $\hat{\mathbf{n}}(\mathbf{x})$ kann also über folgendes Optimierungsproblem gefunden werden:

$$\hat{\mathbf{n}}(\mathbf{x}) = \operatorname{argmax}_{\mathbf{n}} \mathbf{n}^{\top} \mathbf{J}(\mathbf{x}) \mathbf{n} .$$

Die Lösung dieses Optimierungsproblems liefert das Eigenwertproblem:

$$\mathbf{J}(\mathbf{x}) \mathbf{e}(\mathbf{x}) = \lambda(\mathbf{x}) \mathbf{e}(\mathbf{x}) .$$


Der Eigenvektor $\mathbf{e}(\mathbf{x})$ des maximalen Eigenwertes $\lambda_{\max}(\mathbf{x})$ entspricht der Orientierung der lokalen Umgebung $\hat{\mathbf{n}}(\mathbf{x})$. Die Lösung ist folgendermaßen über die Komponenten des Strukturensors gegeben:

$$\hat{\mathbf{n}}(\mathbf{x}) = [J_{22} - J_{11}, 2J_{12}]^{\top} , \quad \text{wobei} \quad \tan(2\hat{\theta}) = 2J_{12} / (J_{22} - J_{11}) .$$

Lokale Strukturen

Beispiel Orientierung der Struktur

Orientation Structure Tensor



Strukturtensor - Kohärenz

Die Kohärenz ist ein Maß für die Isotropie der Grauwertstruktur:

$$c(\mathbf{x}) = \frac{\sqrt{(J_{22} - J_{11})^2 + 4J_{12}^2}}{J_{11} + J_{22}} = \frac{\lambda_1 - \lambda_2}{\lambda_1 + \lambda_2},$$


und variiert zwischen null und eins $c \in [0; 1]$. Eine Struktur mit einer idealen Orientierung hat den Wert eins ($\lambda_2 = 0, \lambda_1 > 0$) und eine komplett isotrope Grauwertstruktur hat den Wert null ($\lambda_1 = \lambda_2 > 0$).

Die Eigenwerte charakterisieren also die Struktur:

- ▶ $\lambda_1 = \lambda_2 = 0$: Die lokale Umgebung ist konstant,
- ▶ $\lambda_1 > 0, \lambda_2 = 0$: Ideale Orientierung, alle Gradienten sind identisch orientiert.
- ▶ $\lambda_1 > 0, \lambda_2 > 0$: Grauwerte ändern sich in alle Richtungen.
- ▶ $\lambda_1 = \lambda_2 > 0$: Grauwerte ändern sich gleichmäßig in alle Richtungen.

Beispiel Eigenwerte Strukturtensor


- Große Eigenwerte nichtlinear abgebildet: $\ln(1 + \lambda_1)$



Beispiel Eigenwerte Strukturtensor

- Kleine Eigenwerte nichtlinear abgebildet: $\ln(1 + \lambda_2)$

Small Eigenvalues Structure Tensor




Lokale Strukturen

Beispiel Kohärenz

- Kohärenz: $(\lambda_1 - \lambda_2)/(\lambda_1 + \lambda_2)$

Coherence Structure Tensor



Strukturtensor - Eckpunkt (corner feature)

Aus den Eigenwerten und der Beziehung zur Kohärenz läßt sich ein sehr einfacher Eckpunkt-Detektor definieren: Wenn der kleinste Eigenwert einen bestimmten vorzugebenden Schwellwert τ überschreitet, dann liegt ein Eckpunkt vor.

Shi-Tomasi corner detector

- ▶ $\min(\lambda_1, \lambda_2) > \tau$: Eckpunkt liegt vor.

Eine weitere Variation dieser Art von Eckpunkt-Detektor haben Harris und Stephens 1988 vorgeschlagen:


Harris corner detector

- ▶ $\det(\mathbf{J}) + k \cdot \text{Spur}^2(\mathbf{J}) = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2 > \tau$: Eckpunkt liegt vor.

Mit $k = [0.04; 0.06]$ kann die Sensitivität gegenüber der Grauwertänderung entlang einer bevorzugten Richtung angepasst werden.


Strukturtensor - Shi-Tomasi Corner Detector

- ▶ $\min(\lambda_1, \lambda_2) > \tau$: Eckpunkt liegt vor.



Strukturtensor - Harris Corner Detector

- $\det(\mathbf{J}) + k \cdot \text{Spur}^2(\mathbf{J}) = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2 > \tau$: Eckpunkt liegt vor.



Vergleich - Harris vs. Shi-Tomasi

Harris Corners



Vergleich - Harris vs. Shi-Tomasi

Shi-Tomasi Corners

